

## 02 - Taxonomía Estándar de Almacenamiento en S3 para el Data Lake Helios Perú

 Este documento establece la **taxonomía estándar de almacenamiento en S3** para las capas del Data Lake:


- **SYNC**
- **LANDING**
- **PREPARATION**
- **360 (Business Data Products)**

### Definiciones Adicionales

Además define:

| Aspecto                                      | Detalle                                                                 |
|----------------------------------------------|-------------------------------------------------------------------------|
| Nomenclatura corporativa de buckets          | Reglas para nombrar los buckets de S3.                                  |
| Reglas de gobernanza                         | Políticas y procedimientos para la gestión de datos.                    |
| Restricciones funcionales                    | Limitaciones en el uso y procesamiento de datos.                        |
| Naming conventions                           | Estándares para nombrar archivos y directorios.                         |
| Cómo se organizan los esquemas de Glue       | Estructura y convenciones para las bases de datos y tablas de AWS Glue. |
| Cómo el esquema Glue mapea a la jerarquía S3 | Relación entre la organización de datos en S3 y los esquemas de Glue.   |

## Flujo de datos end-to-end



El diagrama representa el flujo extremo a extremo de ingesta, preparación, exposición y entrega de datos dentro del Data Lake Helios Perú, operando en una cuenta AWS (ODS) y bajo principios de gobierno del dato.

### Ingesta y Preparación de Datos

Los datos se ingieren desde sistemas relacionales (RDBMS) y archivos externos mediante Hermes y Sync-Lambda, y se almacenan inicialmente en la capa Landing sin transformación.

Desde esta capa, Cefeo orquesta procesos que preparan y tipifican mínimamente los datos en la capa Preparation. Allí, los datasets se registran en el Glue Catalog y están disponibles para consumo analítico vía Athena o EMR. Si se requiere un enriquecimiento mínimo o cálculo de una única fuente para optimizar el procesamiento y obtener información necesaria a nivel de tabla calculada, debe guardarse en una tabla y ruta de enriquecimiento **`${sistema_origen}_Enrichment`**.

### Consolidación y Distribución de Datos

Posteriormente, los datos evolucionan hacia la capa 360, donde se consolidan como productos de datos gobernados, organizados por dominio y listos para el consumo analítico de los usuarios.

De manera controlada, estos productos pueden generar interfaces de salida, delegando a Cefeo la creación de archivos y a Sync / File Movement la distribución hacia productores o consumidores externos, garantizando trazabilidad, segregación de responsabilidades y control en todo el ciclo de vida del dato.

## Nomenclatura de Buckets

### Bucket de SYNC

Intercambio con sistemas externos:

```
1 | obdl-${prefix}-${environment}-${country}-sync-bucket
```

Componentes:

| Componente         | Descripción                                             |
|--------------------|---------------------------------------------------------|
| <b>prefix</b>      | dominio o sistema (ej. <code>scf</code> )               |
| <b>environment</b> | <code>dev</code> , <code>pre</code> , <code>prod</code> |
| <b>country</b>     | código ISO del país (ej. <code>pe</code> )              |

Ejemplo:

```
1 | obdl-scf-pre-pe-sync-bucket
```

 Buckets de capas internas (LANDING / PREPARATION / 360)

```
1 | obdl-${prefix}-${environment}-${country}-notoken-${layer}-bucket
```

Donde `${layer}` ∈ {landing, preparation, 360}

Ejemplo:


```
1 | obdl-scf-pre-pe-notoken-landing-bucket
```

## Layer SYNC – Área de Intercambio

 Propósito

| Característica          | Descripción                                                         |
|-------------------------|---------------------------------------------------------------------|
| Punto de entrada/salida | Punto único de entrada/salida de archivos externos.                 |
| Transformación          | No se transforma, no se tipa, no se renombra.                       |
| Copia automática        | Los archivos se copian automáticamente a LANDING.                   |
| Capa temporal           | Capa <b>temporal</b> con lifecycle (31 días).                       |
| Zona de intercambio     | Los sistemas externos depositan (in) o recogen (out) archivos aquí. |

Estructura S3



Dentro de cada tipo:

```
1 | /${ambiente}/in/${sistema_origen}/${nombre_entidad}/file.extn
2 | /${ambiente}/out/${sistema_destino}/${nombre_entidad}/file.extn
```

Reglas

| Regla               | Descripción                                       |
|---------------------|---------------------------------------------------|
| Formato original    | Mantener formato original (CSV/JSON/TXT/parquet). |
| Exposición a Glue   | No exponer a Glue.                                |
| Data histórica      | No almacenar data histórica.                      |
| Mezcla de ambientes | No mezclar ambientes.                             |


Layer LANDING – Persistencia Cruda

Propósito

- Conservar datos exactamente como se reciben, con mínima manipulación:
  - RDS → **Avro**
  - Streaming → **Avro**

- Ficheros externos → formato original
- Primera capa persistente y trazable.

## Estructura S3



## Reglas

- Lifecycle es que a los 7 días se guarda en Intelligent-tiering y a los 37 se guarda en Glacier Deep Archive.
- Partición obligatoria: `year/month/day`.

- Se puede agregar `hour/minute` si se necesita más precision.
- No lógica de negocio.
- No cálculos ni uniones.
- No exposición directa a Glue.
- `team/` no gobernado.

#### **Reglas de team/:**

- Solo permitido en dev y pre. Prohibido en prod.
  - No gobernado por Glue.
  - El desarrollador es responsable de sus propios artefactos.
  - No se permiten datos.
- 


## **Layer PREPARATION – Tablas Consumibles**

### **Propósito**

- Exponer datasets listos para consumo técnico.
- Transformación mínima:
  - tipado correcto,
  - normalización,
  - columna de auditoría `TST_Preparation`.
- No multi-origen, No lógica de negocio.

### **Restricciones fundamentales:**

- NO multi-origen (no se combinan tablas de distintos sistemas).
- NO lógica de negocio (no se aplican reglas de scoring, KPIs, ni decisiones funcionales)



**Justificación del formato ORC para Snapshots:** Los snapshots representan la foto completa de una tabla, lo que implica volúmenes significativamente mayores que los deltas diarios. ORC ofrece mayor compresión y mejor rendimiento en lectura secuencial para estos volúmenes.

**Diferencia entre Delta y Enrichment:** La capa **Delta** contiene los datos tal como llegan desde el sistema de origen, asegurando únicamente el tipado correcto de los campos. La capa **Enrichment** aplica transformaciones adicionales sobre esos datos, como normalización de cadenas, mapeo de códigos a descripciones y corrección de formatos. Estas transformaciones van más allá del tipado, pero **no** constituyen lógica de negocio.

En el flujo recomendado, el **Enrichment puede aplicarse tanto sobre Delta como sobre Snapshot**. De forma preferente, cuando exista un **Snapshot**, este debe construirse primero y posteriormente aplicar el Enrichment sobre dicha tabla, ya que el Snapshot constituye la base para capas posteriores. En los casos en que no se requiera Snapshot, el Enrichment se aplicará directamente sobre Delta.

En resumen, si la única transformación requerida es el tipado, se utiliza únicamente Delta; si existen normalizaciones o ajustes adicionales, corresponde utilizar Enrichment, independientemente de si la base es Delta o Snapshot.

Reglas de datalake\_test/:

- Solo permitido en dev y pre. Prohibido en prod.
- Puede exponerse a Glue en entornos no productivos para validacion de queries.
- No debe contener datos reales de produccion ni PII.
- Responsable: equipo que crea el test, con aprobacion del Tech Lead.

 Organización de Esquemas en Glue

Glue utiliza una convención directa entre esquema y prefijo S3:

| S3 (carpeta)                        | Glue Database / Schema               | Ejemplo                          |
|-------------------------------------|--------------------------------------|----------------------------------|
| /preparation/data/apian/            | \${evn}_\${country}_apian            | dev_pe_apian.clientes            |
| /preparation/data/apian_snapshot/   | \${evn}_\${country}_apian_snapshot   | dev_pe_apian_snapshot.clientes   |
| /preparation/data/apian_enrichment/ | \${evn}_\${country}_apian_enrichment | dev_pe_apian_enrichment.clientes |
| /preparation/data/cms_snapshot/     | \${evn}_\${country}_cms_snapshot     | dev_pe_cms_snapshot.operaciones  |

 Ejemplo real solicitado

- dev\_pe\_genesis.tabla → corresponde a: /preparation/data/genesis/tabla/
- dev\_pe\_genesis\_snapshot.tabla → corresponde a: /preparation/data/genesis\_snapshot/tabla/

 Tipos de datasets

Preparation contiene tres tipos de datasets internos, todos bajo la misma capa:



✓ A) Delta

- Contiene solo registros del día (incremental).
- Formato: parquet.

✓ B) Snapshot

- Foto completa de la tabla (delta + histórico previo).
- Formato: ORC (más eficiente para grandes volúmenes).

✓ C) Enrichment

**Conjunto de transformaciones simples realizadas sobre UNA sola tabla.**

- Usado para corregir tipos, normalizar, aplicar trims o mapeos simples.
- No permite joins ni multi-origen.
- No contiene lógica de negocio.

---


## Layer 360 – Productos Analíticos de Negocio

### Propósito

Contener **productos 360 gobernados**, generados mediante. Es la capa final del Data Lake. Todo lo que se consume a nivel de negocio proviene de aquí:

- joins multi-origen,
- consolidación,
- KPIs,
- modelos analíticos,
- reglas de negocio.

Es la capa final del Data Lake.



### Consideraciones

- Dominio y subdominio → **funcionales**, nunca técnicos.
- Partición solo por fecha.
- Productos expuestos a Glue.
- Exports NO expuestos a Glue.
- Estructura escalable para múltiples destinos.

### Organización de Esquemas Glue para 360

Glue debe reflejar dominio y subdominio:

| S3 Prefix                         | Glue Schema                   | Tabla Ejemplo     |
|-----------------------------------|-------------------------------|-------------------|
| /360/data/riesgos/credit_scoring/ | dev_pe_riesgos_credit_scoring | score_cliente     |
| /360/data/finanzas/cuentas/       | dev_pe_finanzas_cuentas       | saldo consolidado |

## Regla:

*El esquema Glue =*

`${environment}_${country}_${dominio}_${subdominio}`

Ejemplo: `dev_pe_riesgos_credit_scoring`.

### Ejemplo real solicitado

- `dev_pe_genesis.tabla` → corresponde a:  
`/preparation/data/genesis/tabla/`
- `dev_pe_genesis_snapshot.tabla` → corresponde a:  
`/preparation/data/genesis_snapshot/tabla/`

---

## Interfaces

### Propósito

- Materialización operativa del producto 360 en formatos CSV/JSON/TXT.
- Destinado a otros sistemas (corebanking, campañas, scoring externo, etc.).
- Puede haber múltiples outputs para un mismo producto.

### Reglas

- Los exports **no se mezclan** con los archivos Parquet del producto analítico.
- No se exponen como tablas Glue.
- Pueden tener retención y seguridad diferentes.
- Deben mantenerse **separados** del producto final de negocio

### Aclaración operativa:

La **ETL o ejecución de consultas (sql-runner)** puede generar como salida una **tabla en Glue**, un **fichero**, o **ambos simultáneamente**. No obstante, en todos los casos se trata de **la misma salida de datos**: no existe una versión distinta para la tabla y otra para el fichero.

La **tabla Glue** está orientada a la explotación con servicios de AWS y dashboards internos, mientras que el **fichero** responde a la necesidad de entrega a sistemas consumidores externos, garantizando consistencia y unicidad del dato.

---

### Gobernanza de dominios y subdominios

La creación de nuevos dominios y subdominios requiere aprobación:

| Accion           | Aprobador                  |
|------------------|----------------------------|
| Nuevo dominio    | Comite de Datos / Gobierno |
| Nuevo subdominio | Data Owner del dominio     |
| Nuevo producto   | Tech Lead + Data Owner     |

#### Catalogo de dominios autorizados:

| Dominio   | Descripcion                                    | Data Owner |
|-----------|------------------------------------------------|------------|
| riesgos   | Gestion de riesgos crediticios y operacionales | (Definir)  |
| finanzas  | Consolidacion financiera, cuentas, balances    | (Definir)  |
| comercial | Productos comerciales, campanas, clientes      | (Definir)  |
| core      | Datos transversales (master data, parametros)  | (Definir)  |
| clientes  | Vision unica del cliente                       | (Definir)  |

**Regla:** No se permite crear dominios fuera de este catalogo sin aprobacion del Comite de Datos. Esto evita duplicados como **riesgos** vs **risk** vs **gestion\_riesgos**.

#### Tipos de datasets en 360

| Tipo                        | Contenido                              | Expuesto a Glue | Formato         |
|-----------------------------|----------------------------------------|-----------------|-----------------|
| <b>Dataset (producto)</b>   | Datos analiticos del producto 360      | Si              | Parquet         |
| <b>Interfaces (exports)</b> | Materializacion para sistemas externos | No              | CSV, JSON o TXT |

## abc Naming Convention General

| Regla                     | Aplica a              | Ejemplo correcto   | Ejemplo incorrecto                     |
|---------------------------|-----------------------|--------------------|----------------------------------------|
| Minusculas                | Todo                  | clientes           | Clientes , CLIENTES                    |
| snake_case                | Todo                  | contratos_firmados | contratos-firmados , contratosFirmados |
| Sin espacios              | Todo                  | saldo_consolidado  | saldo consolidado                      |
| Sin caracteres especiales | Todo                  | credit_scoring     | credit-scoring , credit.scoring        |
| Evitar palabras genericas | Entidades y productos | clientes_activos   | datos , tabla1 , output                |

### Naming por capa

| Capa                     | Patron                                               | Ejemplo                              |
|--------------------------|------------------------------------------------------|--------------------------------------|
| SYNC                     | <code>\${sistema_origen}/\${nombre_entidad}</code>   | genesis/clientes                     |
| LANDING                  | <code>\${sistema_origen}/\${nombre_entidad}</code>   | apian/contratos_firmados             |
| PREPARATION - Delta      | <code>\${origen}/\${entidad}</code>                  | genesis/clientes                     |
| PREPARATION - Snapshot   | <code>\${origen}_snapshot/\${entidad}</code>         | genesis_snapshot/clientes            |
| PREPARATION - Enrichment | <code>\${origen}_enrichment/\${entidad}</code>       | genesis_enrichment/clientes          |
| 360                      | <code>\${dominio}/\${subdominio}/\${producto}</code> | riesgos/credit_scoring/score_cliente |

### Formato de particion

**Formato obligatorio: Hive-style con signo =**

```
1 | year=YYYY/month=MM/day=DD
```

### Ejemplos:

```
1 | year=2025/month=01/day=15
2 | year=2025/month=01/day=15/hour=08/minute=30    (solo si aplica)
```

**Importante:** No se acepta el formato plano ( 2025/01/15 ). El formato Hive-style permite a Athena, Glue y EMR inferir particiones automáticamente.